



ΠΑΝΕΠΙΣΤΗΜΙΟ
ΠΑΤΡΩΝ
UNIVERSITY OF PATRAS

Πανεπιστημιούπολη Ρίου · Πολυτεχνική Σχολή
Τμήμα Μηχανικών Η/Υ & Πληροφορικής (ΤΜΗΥΠ – CEID)

ΤΟΠΟΛΟΓΙΚΗ ΑΝΑΛΥΣΗ ΔΕΔΟΜΕΝΩΝ

(CEID_25EE606)

Εξαμηνιαία Εργασία — 2026

Ομάδα Εργασίας:

Βερύκιος Άγγελος (1100500)

Βογινατζής Αναστάσιος (1100506)

Κολύβρας Κωνσταντίνος (1103826)

11 Μαΐου 2026

Περιεχόμενα

1	<u>Θεωρητική Εισαγωγή</u>	2
1.1	Simplicial Complexes	2
1.2	Persistent Homology	2
1.3	Mapper	2
2	<u>Μεθοδολογία</u>	3
2.1	Βιβλιοθήκες	3
2.2	Αιτιολόγηση Επιλογών	3
3	<u>Αποτελέσματα & Ανάλυση</u>	4
3.1	Ερώτημα Α	4
3.1.1	A.1—Νέφος Σημείων & Vietoris–Rips (from scratch)	4
3.1.2	A.2—Σύγκριση VR/Cech/Alpha μέσω GUDHI	5
3.1.3	A.3—Filtration & Ανάλυση Κλίμακας	6
3.1.4	A.4—Οπτικοποίηση σε 3 Διαστάσεις (3D)	7
3.2	Ερώτημα Β	8
3.2.1	B.1: Persistent Homology από Νέφη Σημείων	8
3.2.2	B.2: Στιβαρότητα (Robustness) σε Gaussian Θόρυβο	8
3.2.3	B.3: Persistent Homology σε Γράφους	9
3.3	Ερώτημα Γ	11
3.3.1	Γ.1: Υλοποίηση Mapper εκ του Μηδενός	11
3.3.2	Γ.2: Εφαρμογή Mapper & Ανάλυση Ευαισθησίας	11
3.4	Ερώτημα Δ — Εφαρμογή σε Πραγματικά Δεδομένα	13
3.4.1	Δ.1 — Ανάλυση Πρώτου Dataset (Breast Cancer)	13
3.4.2	Δ.2 — Ανάλυση Δεύτερου Dataset (S&P 500)	14
3.4.3	Δ.3 — Βαθιά Σύγκριση & Συζήτηση: TDA vs Κλασικές Μέθοδοι	16
3.5	Ερώτημα Ε — Zigzag Persistent Homology	17
3.5.1	E.1 — Zigzag Persistent Homology σε Χρονοσειρές	17
3.5.2	E.2 — Topological Loss σε Neural Network	19
4	<u>Συμπεράσματα</u>	21
5	<u>Χρήση AI</u>	22
6	<u>Βιβλιογραφία</u>	23

1 Θεωρητική Εισαγωγή

Στην ενότητα αυτή παρουσιάζονται οι βασικές έννοιες της Τοπολογικής Ανάλυσης Δεδομένων (TDA).

1.1 **Simplicial Complexes**

Τα Simplicial Complexes αποτελούν τη διακριτή προσέγγιση των συνεχών τοπολογικών χώρων. Αποτελούνται από απλόπλοκα (simplices) διαφόρων διαστάσεων: 0-απλόπλοκα (σημεία), 1-απλόπλοκα (ακμές), 2-απλόπλοκα (τρίγωνα), 3-απλόπλοκα (τετράεδρα) κ.ο.κ. Η ένωση αυτών των στοιχείων με συγκεκριμένους κανόνες συνδυαστικότητας μας επιτρέπει να μοντελοποιήσουμε το σχήμα των δεδομένων και να υπολογίσουμε τοπολογικές ιδιότητες.

1.2 **Persistent Homology**

Η Persistent Homology είναι ένα εργαλείο που ανιχνεύει τοπολογικά χαρακτηριστικά (όπως συνεκτικές συνιστώσες, τρύπες, κοιλότητες) σε πολλαπλές κλίμακες. Καθώς αυξάνουμε την ακτίνα r γύρω από κάθε σημείο (διήθηση ή filtration), νέα απλόπλοκα δημιουργούνται. Η εμμονή (persistence) μετρά πόσο ‘ζει’ κάθε τοπολογικό χαρακτηριστικό. Χαρακτηριστικά που επιμένουν για μεγάλο εύρος τιμών του r θεωρούνται αληθή τοπολογικά σήματα, ενώ αυτά που πεθαίνουν γρήγορα θεωρούνται θόρυβος.

1.3 **Mapper**

Ο αλγόριθμος Mapper είναι μια τεχνική μείωσης διαστάσεων και οπτικοποίησης που διατηρεί την τοπολογική δομή των δεδομένων. Χρησιμοποιεί μια συνάρτηση φίλτρου (filter function) για να προβάλλει τα δεδομένα σε χαμηλότερη διάσταση, χωρίζει τον χώρο σε επικαλυπτόμενα διαστήματα, εφαρμόζει clustering στα σημεία κάθε διαστήματος και συνδέει τα clusters που μοιράζονται κοινά σημεία, δημιουργώντας ένα γράφημα που συνοψίζει τη δομή.

2 Μεθοδολογία

Για την υλοποίηση της εργασίας ακολουθήθηκε η εξής διαδικασία:

2.1 Βιβλιοθήκες

- GUDHI: Για την κατασκευή συμπλεγμάτων και τον υπολογισμό Persistent Homology στο Ερώτημα A.
- Ripser: Για τον γρήγορο υπολογισμό της Persistent Homology στο Ερώτημα B.
- Persim: Για τον υπολογισμό αποστάσεων Bottleneck και Wasserstein.
- NumPy & SciPy: Για τη διαχείριση δεδομένων και μαθηματικούς υπολογισμούς.
- Matplotlib & Plotly: Για την οπτικοποίηση των αποτελεσμάτων.

2.2 Αιτιολόγηση Επιλογών

Η επιλογή της GUDHI έγινε λόγω της πληρότητάς της σε διάφορα είδη συμπλεγμάτων (Alpha Complex, Cech Complex κ.λπ.), ενώ η Ripser επιλέχθηκε για την ταχύτητά της στον υπολογισμό του H_1 . Ο αλγόριθμος Mapper υλοποιήθηκε τόσο εκ του μηδενός (για βαθύτερη κατανόηση) όσο και μέσω της βιβλιοθήκης `kmapper` για επαλήθευση των αποτελεσμάτων.

3 Αποτελέσματα & Ανάλυση

3.1 Ερώτημα Α

3.1.1 A.1—Νέφος Σημείων & Vietoris–Rips (from scratch)


Εξήγηση Υλοποίησης: Για την υλοποίηση εκ του μηδενός, δημιουργήσαμε τα νέφη σημείων και υπολογίσαμε τον πίνακα αποστάσεων. Στη συνέχεια, για μια δεδομένη ακτίνα r , βρήκαμε όλες τις ακμές (αποστάσεις $\leq 2r$) και όλα τα τρίγωνα (κλίκες μεγέθους 3). Ο υπολογισμός των αριθμών Betti έγινε μέσω του πίνακα συνόρων (boundary matrix) και απαλοιφής Gauss.

Σημαντικό Κομμάτι Κώδικα:

```
1 # Finding edges and triangles (Simplices)
2 edges = []
3 for i in range(n):
4     for j in range(i+1, n):
5         if dist_matrix[i, j] <= 2 * r:
6             edges.append((i, j))
7
8 triangles = []
9 for i in range(n):
10     for j in range(i+1, n):
11         for k in range(j+1, n):
12             if dist_matrix[i, j] <= 2*r and dist_matrix[i, k] <= 2*r
13                 and dist_matrix[j, k] <= 2*r:
14                 triangles.append((i, j, k))
```

Σχολιασμός: Ο κώδικας αυτός ελέγχει όλους τους συνδυασμούς σημείων για να βρει αν σχηματίζουν ακμές ή τρίγωνα με βάση την ακτίνα r . Είναι η βάση για την κατασκευή του συμπλέγματος.

Αποτελέσματα & Ερμηνεία: Τα αποτελέσματα του υπολογισμού των αριθμών Betti για τον κύκλο με $\epsilon = 0.5$ έδωσαν $\beta_0 = 1$, $\beta_1 = 1$, $\beta_2 = 1$. Σημείωση: Η τιμή $\beta_2 = 1$ οφείλεται στην αποκοπή του συμπλέγματος στη διάσταση 2 (έλλειψη τετραέδρων).



Σχήμα 1: Τα 4 παραγόμενα νέφη σημείων. Παρατηρούμε τις διαφορετικές τοπολογικές δομές (κύκλος, τόρος, σφαίρα).


3.1.2 A.2—Σύγκριση VR/Cech/Alpha μέσω GUDHI

Αποτελέσματα & Ερμηνεία:

Πίνακας 1: Σύγκριση Συμπλεγμάτων για $r = 0.3$

Σύμπλεγμα	0-simplices	1-simplices	2-simplices	β_0	β_1	β_2
VR Complex	30	72	54	1	1	0
Cech Complex	30	56	26	1	1	0
Alpha Complex	30	37	7	1	1	0


Παρατηρούμε ότι το Alpha Complex παράγει πολύ λιγότερα απλόπλακα (ακμές και τρίγωνα) σε σχέση με το VR, αλλά διατηρεί τους ίδιους αριθμούς Betti. Αυτό το καθιστά πολύ πιο αποδοτικό.




Σχήμα 2: Οπτικοποίηση του VR Complex. Τα σημεία είναι μπλε, οι ακμές κόκκινες και τα τρίγωνα πράσινα.

3.1.3 A.3—Filtration & Ανάλυση Κλίμακας

Αποτελέσματα & Ερμηνεία: Η τρύπα του κύκλου γεννιέται στο $r = 0.2$ (όταν οι ακμές κλείνουν τον κύκλο) και πεθαίνει στο $r = 0.9$ (όταν τα τρίγωνα γεμίζουν τον κύκλο).




Σχήμα 3: Διάγραμμα αριθμών Betti. Στο $r = 0.2$ εμφανίζεται ο $\beta_1 = 1$.



Σχήμα 4: Στιγμιότυπα της κατασκευής του συμπλέγματος για διάφορες τιμές του r .

3.1.4 A.4—Οπτικοποίηση σε 3 Διαστάσεις (3D)

Εξήγηση Υλοποίησης: Για τις δομές σε 3 διαστάσεις (όπως ο Τόρος και η Σφαίρα), η οπτικοποίηση του συμπλέγματος Vietoris–Rips απαιτεί την εμφάνιση των σημείων, των ακμών αλλά και των τριγώνων (2-simplices) στον τρισδιάστατο χώρο. Αυτό βοηθά στην κατανόηση του πώς τα απλόπλοκα ‘γεμίζουν’ τον χώρο και σχηματίζουν τις τοπολογικές τρύπες.



Σχήμα 5: Οπτικοποίηση του συμπλέγματος σε 3 διαστάσεις (3D) για τον Τόρο από δύο διαφορετικές οπτικές γωνίες.

3.2 Ερώτημα Β

3.2.1 B.1: Persistent Homology από Νέφη Σημείων


Εξήγηση Υλοποίησης: Χρησιμοποιήσαμε τη βιβλιοθήκη Ripser για τον υπολογισμό των διαγραμμάτων εμμονής. Η Ripser είναι εξαιρετικά γρήγορη και αποδοτική για αυτόν τον σκοπό.

Σημαντικό Κομμάτι Κώδικα:


```
1 from ripser import ripser
2 # Calculate Persistent Homology
3 result = ripser(data, maxdim=2)
4 diagrams = result['dgms']
```

Σχολιασμός: Η συνάρτηση *ripser* υπολογίζει αυτόματα τα διαγράμματα εμμονής μέχρι τη διάσταση που ορίζουμε (*maxdim*).

Αποτελέσματα & Ερμηνεία: Τα σημεία που βρίσκονται μακριά από τη διαγώνιο αντιπροσωπεύουν πραγματικά τοπολογικά χαρακτηριστικά που επιμένουν, ενώ τα σημεία κοντά στη διαγώνιο είναι θόρυβος.




Σχήμα 6: Persistence Diagrams για Τυχαία Σημεία και Θορυβώδη Κύκλο.



Σχήμα 7: Persistence Diagrams για Τόρο και Σφαίρα.

3.2.2 B.2: Στιβαρότητα (Robustness) σε Gaussian Θόρυβο


Αποτελέσματα & Ερμηνεία: Όπως φαίνεται στο διάγραμμα, η απόσταση Bottleneck και Wasserstein αυξάνεται καθώς αυξάνεται ο θόρυβος σ . Αυτό δείχνει την ευαισθησία των τοπολογικών χαρακτηριστικών στον θόρυβο.




Σχήμα 8: Επίδραση του θορύβου στις αποστάσεις Bottleneck και Wasserstein.

3.2.3 B.3: Persistent Homology σε Γράφους

Αποτελέσματα & Ερμηνεία: Υπολογίστηκαν δύο διαφορετικές διηθήσεις (filtrations). Τα αποτελέσματα δείχνουν πώς η επιλογή της διήθησης επηρεάζει τα τοπολογικά χαρακτηριστικά που ανιχνεύονται.



Σχήμα 9: Σύγκριση Persistence Diagrams για γράφους.



Σχήμα 10: Persistence Images για τους γράφους.

3.3 Ερώτημα Γ

3.3.1 Γ.1: Υλοποίηση Mapper εκ του Μηδενός

Εξήγηση Υλοποίησης: Υλοποιήσαμε τον αλγόριθμο Mapper από το μηδέν. Ο αλγόριθμος χωρίζει τον χώρο των τιμών του φίλτρου σε επικαλυπτόμενα διαστήματα, ομαδοποιεί τα σημεία που αντιστοιχούν σε κάθε διάστημα (χρησιμοποιώντας DBSCAN) και συνδέει τους κόμβους που μοιράζονται κοινά σημεία.


Σημαντικό Κομμάτι Κώδικα:

```
1 # Main logic of fit method in CustomMapper
2 for int_idx, interval_bounds in enumerate(intervals):
3     # Find points in interval
4     pts_idx = np.where(in_interval)[0]
5     # Cluster subset of points
6     labels = self.clustering_algo.fit_predict(X_subset)
7     # Add nodes and edges to graph
```

Σχολιασμός: Η λογική αυτή διατρέχει όλα τα διαστήματα και εφαρμόζει *clustering* για να βρει τους κόμβους του γραφήματος.


3.3.2 Γ.2: Εφαρμογή Mapper & Ανάλυση Ευαισθησίας

Αποτελέσματα & Ερμηνεία: Εφαρμόσαμε τον αλγόριθμο στα σύνολα δεδομένων Figure-8 και Horse-shoe με 3 διαφορετικές συναρτήσεις φίλτρου: PCA 1ης συνιστώσας, L2-norm και Density.




Σχήμα 11: Αποτελέσματα Custom Mapper για το Figure-8 με φίλτρα PCA, L2-norm και Density.

Σχολιασμός: Η τριάδα των γραφημάτων για το Figure-8 διαφέρει ανάλογα με το φίλτρο: 1. Το PCA διαχωρίζει τους δύο κύκλους (αριστερά-δεξιά) στον άξονα μέγιστης διασποράς. 2. Το L2-norm δείχνει την απόσταση από το κέντρο, δημιουργώντας μια δομή που 'ανοίγει' από το κέντρο προς τα άκρα. 3. Το Density αναδεικνύει το σημείο τομής των δύο κύκλους όπου η πυκνότητα των σημείων είναι μέγιστη.



Σχήμα 12: Αποτελέσματα Custom Mapper για το Horse-shoe με φίλτρα PCA, L2-norm και Density.

Σχολιασμός: Στο *Horse-shoe*: 1. Το PCA 'ξεδιπλώνει' την καμπύλη σε μια συνεχή γραμμική δομή. 2. Το *L2-norm* δίνει παρόμοιες τιμές σε όλα τα σημεία (αφού ισαπέχουν από το κέντρο), συμπυκνώνοντας το γράφημα. 3. Το *Density* δείχνει ότι η πυκνότητα είναι ομοιόμορφη κατά μήκος του πετάλου, διατηρώντας τη δομή ως μία συνεκτική συνιστώσα.



Σχήμα 13: Ανάλυση ευαισθησίας: Αριθμός συνεκτικών συνιστωσών συναρτήσει των παραμέτρων.

Σχολιασμός: Η ανάλυση ευαισθησίας δείχνει ότι ο αριθμός των συνεκτικών συνιστωσών εξαρτάται έντονα από τον αριθμό των διαστημάτων και το ποσοστό επικάλυψης. Μεγαλύτερη επικάλυψη οδηγεί σε πιο συνεκτικά γραφήματα.


3.4 Ερώτημα Δ — Εφαρμογή σε Πραγματικά Δεδομένα

Σε αυτή την ενότητα εφαρμόζουμε τις τεχνικές της Τοπολογικής Ανάλυσης Δεδομένων (TDA) σε δύο πραγματικά σύνολα δεδομένων: το dataset καρκίνου του μαστού (Breast Cancer Wisconsin) ως Κατηγορία I και τις χρονοσειρές των τιμών κλεισίματος του δείκτη S&P 500 των τελευταίων δύο ετών ως Κατηγορία II.

3.4.1 Δ.1 — Ανάλυση Πρώτου Dataset (Breast Cancer)

1. Προεπεξεργασία και Μείωση Διάστασης: Το σύνολο δεδομένων Breast Cancer περιλαμβάνει 569 δείγματα με 30 αριθμητικά χαρακτηριστικά που περιγράφουν πυρήνες κυττάρων από βιοψίες μαστού. Τα δεδομένα κατηγοριοποιούνται σε δύο κλάσεις: Malignant (κακοήθης, 212 δείγματα) και Benign (καλοήθης, 357 δείγματα). Πραγματοποιήθηκε τυποποίηση (Standardization) των δεδομένων με χρήση του `StandardScaler` ώστε όλα τα χαρακτηριστικά να έχουν μέση τιμή 0 και διασπορά 1. Στη συνέχεια, εφαρμόστηκε η μέθοδος PCA κρατώντας τις 5 κύριες συνιστώσες για τη διευκόλυνση του υπολογισμού της επίμονης ομολογίας.

2. Επίμονη Ομολογία (H_0, H_1): Υπολογίστηκε η επίμονη ομολογία για τις διαστάσεις 0 και 1 ξεχωριστά για την κλάση των κακοήθων και των καλοήθων δειγμάτων χρησιμοποιώντας τη βιβλιοθήκη `ripser`. Τα αποτελέσματα οπτικοποιούνται στα διαγράμματα εμμονής (Persistence Diagrams) και barcodes.



Σχήμα 14: Persistence Diagrams για την κλάση Malignant (αριστερά) και Benign (δεξιά).

Παρατηρούμε ότι οι δύο κλάσεις παρουσιάζουν διαφορές στην τοπολογική τους δομή. Η κλάση των καλοήθων δειγμάτων εμφανίζει πιο διάσπαρτα και μακρόβια χαρακτηριστικά H_1 (τρύπες) σε σχέση με την κλάση των κακοήθων, πράγμα που υποδηλώνει μια πιο σύνθετη και «ανοιχτή» γεωμετρική διάταξη στο χώρο των κύριων συνιστωσών.

3. Εφαρμογή Mapper: Κατασκευάστηκε το γράφημα Mapper χρησιμοποιώντας τη βιβλιοθήκη `kmapper`. Ως συνάρτηση φίλτρου χρησιμοποιήθηκε η προβολή PCA σε 2 διαστάσεις. Ο χώρος καλύφθηκε από 10 επικαλυπτόμενα διαστήματα με ποσοστό επικάλυψης 30% ανά διάσταση, και εφαρμόστηκε ο αλγόριθμος DBSCAN (με `eps=2.5` και `min_samples=3`) για το clustering των σημείων. Το διαδραστικό γράφημα Mapper αποθηκεύτηκε στο αρχείο `d1_mapper_graph.html`.

Το γράφημα αναδεικνύει τον διαχωρισμό των κλάσεων σε διαφορετικές περιοχές (branches) του γραφήματος, με μια περιοχή μετάβασης όπου συνυπάρχουν καλοήγη και κακοήγη δείγματα.

4. TDA ως Χαρακτηριστικά (Features) για Μηχανική Μάθηση: Για να χρησιμοποιήσουμε την τοπολογική πληροφορία σε ταξινόμηση, μετατρέψαμε το διάνυσμα χαρακτηριστικών κάθε ασθενούς (30 τιμές) σε χρονοσειρά / point cloud μέσω της μεθόδου Takens Embedding (με διάσταση 3 και καθυστέρηση 1). Στη συνέχεια, για κάθε ασθενή υπολογίστηκε η επίμονη ομολογία H_0 και τα διαγράμματα εμμονής μετατράπηκαν σε εικόνες εμμονής (Persistence Images) μέσω του PersistenceImager (με μέγεθος pixel 0.1). Οι εικόνες αυτές ισοπεδώθηκαν (flatten) σε μονοδιάστατα διανύσματα χαρακτηριστικών. Εκπαιδεύτηκε ένας ταξινομητής Random Forest με τα παρακάτω αποτελέσματα στο test set (30%):

- **Accuracy:** 0.6901
- **AUC Score:** 0.7152

Αν και η ακρίβεια αυτή είναι χαμηλότερη από τη χρήση των αρχικών δεδομένων άμεσα (καθώς το Takens embedding σε 30 features εισάγει θόρυβο), επιβεβαιώνει ότι η καθαρά τοπολογική δομή των χαρακτηριστικών φέρει σημαντική διακριτική ικανότητα για τη διάγνωση του καρκίνου.

3.4.2 Δ.2 — Ανάλυση Δεύτερου Dataset (S&P 500)

1. Δεδομένα και Giotto-TDA Pipeline: Φορτώθηκαν οι καθημερινές τιμές κλεισίματος του δείκτη S&P 500 (`^GSPC`) για τα τελευταία 2 έτη μέσω της `yfinance`. Οι τιμές τυποποιήθηκαν και εφαρμόστηκε η μέθοδος Takens Embedding με διάσταση $d = 3$ και καθυστέρηση $\tau = 1$, μετατρέποντας τη μονοδιάστατη χρονοσειρά σε ένα τρισδιάστατο point cloud που αναπαριστά τη δυναμική της αγοράς. Κατασκευάστηκε ένα scikit-learn συμβατό pipeline μέσω της βιβλιοθήκης `giotto-tda` που περιλαμβάνει:


1. `TakensEmbedding` για την αναπαράσταση της χρονοσειράς σε 3D.
2. `VietorisRipsPersistence` για τον υπολογισμό των διαγραμμάτων εμμονής για τις διαστάσεις 0, 1 και 2.
3. `PersistenceEntropy` για τον υπολογισμό της επίμονης εντροπίας ως μέτρο πολυπλοκότητας της τοπολογίας της χρονοσειράς.

Η κανονικοποιημένη επίμονη εντροπία (Normalized Persistence Entropy) για το σύνολο των δεδομένων υπολογίστηκε σε:

- H_0 : 1.6775
- H_1 : 8.6782
- H_2 : -0.6358


2. Επαλήθευση H_2 Ομολογίας με GUDHI: Επειδή η διάσταση του point cloud είναι $d \geq 3$, υπολογίστηκε η ομολογία διάστασης 2 (H_2). Χρησιμοποιήθηκε το `AlphaComplex` της βιβλιοθήκης GUDHI για την επαλήθευση. Οι αριθμοί Betti που προέκυψαν ήταν $\beta = [1, 0, 0]$, γεγονός που δείχνει ότι το σύμπλεγμα είναι τοπολογικά ισοδύναμο με ένα μόνο σημείο (συνεχτικό σύμπλεγμα χωρίς 1-κύκλους ή 2-κοιλότητες στην τελική κλίμακα), επιβεβαιώνοντας ότι το Takens Embedding της χρηματοοικονομικής χρονοσειράς δεν σχηματίζει κλειστές σφαιρικές κοιλότητες ($H_2 = 0$).

3. Οπτικοποίηση και Μείωση Διάστασης: Η 3D τροχιά του Takens Embedding οπτικοποιήθηκε σε διαδραστικό γράφημα Plotly (d2-sp500-3d-embedding.html). Επιπλέον, το 3D point cloud οπτικοποιήθηκε και σε στατικό τρισδιάστατο γράφημα στο Σχήμα 15.



Σχήμα 15: Τρισδιάστατη τροχιά του Takens Embedding ($d = 3, \tau = 1$) για τη χρονοσειρά S&P 500.

Για τη σύγκριση, το 3D point cloud προβλήθηκε σε 2 διαστάσεις με 3 μεθόδους: PCA, t-SNE και UMAP, όπως φαίνεται στο Σχήμα 16.



Σχήμα 16: Σύγκριση μείωσης διάστασης του 3D Takens Embedding του S&P 500 με PCA, t-SNE και UMAP.

- Η PCA αποκαλύπτει τη γραμμική κατεύθυνση μέγιστης διασποράς της αγοράς.
- Το t-SNE δημιουργεί ξεχωριστές συστάδες, τονίζοντας τοπικές ομοιότητες αλλά καταστρέφοντας την παγκόσμια γεωμετρία της χρονοσειράς.
- Το UMAP διατηρεί καλύτερα τη συνέχεια της τροχιάς της χρονοσειράς, αναδεικνύοντας τη δομή «νήματος» (filament structure) των τιμών.

4. Bootstrap Resampling & Διαστήματα Εμπιστοσύνης (95%): Για να ελέγξουμε τη σταθερότητα της επίμονης εντροπίας, εφαρμόστηκε bootstrap resampling ($n = 100$) με τυχαία επιλογή του 80% των σημείων με επανατοποθέτηση. Τα 95% διαστήματα εμπιστοσύνης για την επίμονη εντροπία είναι:

- H_0 : Mean = 1.7014, 95% CI = [1.6596, 1.7349]
- H_1 : Mean = -12.2571, 95% CI = [-28.6147, -4.8745]
- H_2 : Mean = -0.2339, 95% CI = [-1.0000, -0.0000]

Τα στενά διαστήματα εμπιστοσύνης για το H_0 δείχνουν τη σταθερότητα της βασικής συνεκτικότητας των δεδομένων, ενώ οι αρνητικές τιμές και η διακύμανση στο H_1 και H_2 υποδηλώνουν την ευαισθησία και τον θόρυβο των ανώτερων τοπολογικών χαρακτηριστικών όταν υποδειγματίζεται το point cloud της χρονοσειράς.

3.4.3 Δ.3 — Βαθιά Σύγκριση & Συζήτηση: TDA vs Κλασικές Μέθοδοι

Η εφαρμογή των TDA μεθόδων στα δύο datasets ανέδειξε τα εξής πλεονεκτήματα έναντι των PCA, t-SNE και UMAP:

1. **Πολλαπλές Κλίμακες:** Οι κλασικές μέθοδοι μείωσης διάστασης απαιτούν την επιλογή μιας συγκεκριμένης κλίμακας (π.χ. perplexity στο t-SNE ή `n_neighbors` στο UMAP). Αντίθετα, η επίμονη ομολογία εξετάζει όλες τις κλίμακες ταυτόχρονα (μέσω του filtration r), διαχωρίζοντας με μαθηματική αυστηρότητα το σήμα από τον θόρυβο.
2. **Feature Extraction:** Η TDA επιτρέπει τη μετατροπή γεωμετρικών ιδιοτήτων σε ποσοτικά χαρακτηριστικά (όπως η Persistent Entropy και οι Persistence Images) που εισάγονται άμεσα σε μοντέλα μηχανικής μάθησης. Οι κλασικές μέθοδοι (όπως το t-SNE) δεν ορίζουν εύκολα μια αντίστροφη απεικόνιση ή μια γενικεύσιμη μεταμόρφωση για νέα δεδομένα (out-of-sample extension).
3. **Διατήρηση Σχήματος:** Ο Mapper και η επίμονη εντροπία αποτυπώνουν το «σχήμα» των δεδομένων (π.χ. βρόχους, διακλαδώσεις, κοιλότητες) το οποίο οι κλασικές προβολές (κυρίως η PCA) συμπιέζουν και καταστρέφουν. Στην ανάλυση χρονοσειρών (S&P 500), η TDA σε συνδυασμό με το Takens Embedding προσφέρει μια πλήρη εικόνα του χώρου φάσεων (phase space reconstruction), επιτρέποντας την ανίχνευση τοπολογικών αλλαγών που σχετίζονται με περιόδους αστάθειας στην αγορά.

3.5 Ερώτημα Ε — Zigzag Persistent Homology


3.5.1 Ε.1 — Zigzag Persistent Homology σε Χρονοσειρές

1. Μεθοδολογία και Κατασκευή: Για την καταγραφή της δυναμικής εξέλιξης των τοπολογικών χαρακτηριστικών της χρονοσειράς του δείκτη S&P 500, εφαρμόσαμε τη μέθοδο της Zigzag Persistent Homology. Η μονοδιάστατη χρονοσειρά μετατράπηκε σε ακολουθία point clouds μέσω Sliding Window με μέγεθος παραθύρου $W = 50$ ημέρες και βήμα $S = 25$ ημέρες, χρησιμοποιώντας Takens Embedding με διάσταση $d = 3$ και καθυστέρηση $\tau = 1$.

Η κατασκευή της zigzag filtration έγινε με την εναλλαγή forward και backward inclusions:

$$K_0 \hookrightarrow K_0 \cup K_1 \hookleftarrow K_1 \hookrightarrow K_1 \cup K_2 \hookleftarrow K_2 \hookrightarrow \dots$$

όπου K_i είναι το Rips complex του i -οστού παραθύρου για ακτίνα Rips $\epsilon = 2 \times 0.1524 = 0.3048$ (η 15η εκατοστημόρια θέση των αποστάσεων). Ο υπολογισμός των αριθμών Betti έγινε μέσω απαλοιφής Gauss σε GF(2) πάνω στους αντίστοιχους πίνακες συνοριακών απεικονίσεων (∂_1, ∂_2) .




Σχήμα 17: Sliding windows στη χρονοσειρά S&P 500 που χρησιμοποιήθηκαν για την κατασκευή των point clouds.

2. Αποτελέσματα και Σχολιασμός:

- **Συνεκτικότητα (H_0):** Εντοπίστηκαν 13 intervals στην H_0 . Το κυρίαρχο interval έχει διάρκεια 19.0 steps (από $t = 0$ έως $t = 19$), που αντιστοιχεί στη βασική συνεκτική δομή που επιβιώνει σε όλα τα παράθυρα. Παρατηρείται ένα σημαντικό spike στο $t = 16$ (παράθυρο K_8), όπου ο αριθμός των συνεκτικών συνιστωσών αυξάνεται σε $\beta_0 = 9$, υποδηλώνοντας τοπολογική διάσπαση του point cloud κατά τη διάρκεια περιόδου υψηλής μεταβλητότητας στην αγορά.
- **Τοπολογικοί Κύκλοι (H_1):** Εντοπίστηκε 1 interval στην H_1 με διάρκεια 1.0 step. Η κλασική PH ανά παράθυρο δίνει μέσο $\beta_1 = 0.00 \pm 0.00$. Αυτό δείχνει ότι τα μεμονωμένα παράθυρα δεν περιέχουν μόνιμους κύκλους, αλλά η zigzag PH ανιχνεύει έναν μεταβατικό (transient) κύκλο που δημιουργείται κατά την ένωση $K_i \cup K_{i+1}$.

E.1 — Σύγκριση Zigzag vs Κλασικής Persistent Homology (S&P 500)



Σχήμα 18: Συγκεντρωτικό διάγραμμα σύγκρισης: Zigzag Persistence Diagram (πάνω αριστερά), Zigzag Barcode (πάνω δεξιά) και εξέλιξη των Betti αριθμών β_0 (κάτω αριστερά) και β_1 (κάτω δεξιά) σε σύγκριση με την κλασική PH.

3. Σύγκριση με Κλασική Persistent Homology: Η κλασική PH αναλύει κάθε παράθυρο ανεξάρτητα και στατικά, χάνοντας τη χρονική συσχέτιση των χαρακτηριστικών. Αντίθετα, η zigzag PH συνδέει τα τοπολογικά χαρακτηριστικά μεταξύ διαδοχικών παραθύρων μέσω των union complexes.

Όπως επιβεβαιώνεται στα διαγράμματα του Σχήματος 18, στα άρτια βήματα $t = 2i$ οι Betti αριθμοί της zigzag PH ταυτίζονται απόλυτα με τους Betti αριθμούς της κλασικής PH στο παράθυρο i , ενώ τα ενδιάμεσα περιττά βήματα αποτυπώνουν με ακρίβεια τη δυναμική μετάβαση (ένωση) μεταξύ τους.

3.5.2 E.2 — Topological Loss σε Neural Network

1. Μεθοδολογία και Υλοποίηση: Στην ενότητα αυτή υλοποιούμε ένα Topological Regularization Loss για Multi-Layer Perceptron (MLP) εκ του μηδενός (χρησιμοποιώντας μόνο NumPy) και το εφαρμόζουμε στο Breast Cancer Wisconsin dataset για binary classification (δυαδική ταξινόμηση Malignant/Benign). Ο στόχος είναι να μελετήσουμε αν το topological regularization της ενδιάμεσης αναπαράστασης βελτιώνει τη δομή του latent space.

Το Topological Loss βασίζεται στην H_0 persistent homology μέσω Vietoris-Rips filtration και ορίζεται ως:

$$\mathcal{L}_{\text{τοπο}} = \lambda \sum_k d_k^2$$

όπου $d_k = \text{διστ}(i_k, j_k)$ είναι το death κάθε H_0 persistence pair (δηλαδή η απόσταση μεταξύ των δύο σημείων που ενώνουν δύο connected components κατά τη filtration). Η αναλυτική παράγωγος ως προς τα activations $\mathbf{x}_i$ του latent space υπολογίζεται αποδοτικά σε $O(n^2 \log n)$ ανά batch μέσω της Υνιον-Φινδ δομής:


$$\frac{\partial \mathcal{L}_{\text{τοπο}}}{\partial \mathbf{x}_i} = 2\lambda (\mathbf{x}_i - \mathbf{x}_j)$$

Η αρχιτεκτονική του δικτύου είναι $\text{input}(10) \rightarrow \text{hidden}(64, \text{ReLU}) \rightarrow \text{hidden}(32, \text{ReLU}) \rightarrow \text{output}(1, \text{Sigmoid})$. Τα δεδομένα μειώνονται σε 10 features μέσω PCA (διατήρηση $> 95\%$ διακύμανσης) και διαχωρίζονται σε Train/Val/Test (64%/16%/20%). Το Baseline MLP εκπαιδεύεται με binary cross-entropy (lr=0.005, batch size=32, 80 epochs), ενώ στο Topo-MLP προστίθεται το $\mathcal{L}_{\text{τοπο}}$ ($\lambda_{\text{τοπο}} = 0.001$) από το epoch 20.


2. Αποτελέσματα και Σχολιασμός: Η αξιολόγηση στο Test Set δείχνει ότι η εισαγωγή του Topological Loss μειώνει σημαντικά τη μέση H_0 persistence του latent space κατά **55

Πίνακας 2: Σύγκριση Baseline MLP ς Topo-MLP στο Test Set (80 epochs)


Μοντέλο	Accuracy	AUC-ROC	Μέση H_0 Persistence
Baseline MLP	0.9737	0.9917	4.7194
Topo-MLP	0.9737	0.9871	2.1028




Σχήμα 19: Training curves του Validation και εξέλιξη του Topological Loss.



Σχήμα 20: ROC curves των μοντέλων στο Test Set.



Σχήμα 21: PCA 2D προβολή του τελευταίου hidden layer (Malignant κόκκινο, Benign μπλε).



Σχήμα 22: H_0 Persistence Diagrams των αντίστοιχων latent spaces.

3. Συζήτηση και Συμπεράσματα:

- **Τοπολογική Δομή:** Το Topological Loss συμπιέζει τον latent space αναγκάζοντας τα δείγματα της ίδιας κλάσης να σχηματίσουν πιο συνεκτικές ομάδες, γεγονός που αποδεικνύεται από τη μείωση της H_0 persistence από 4.72 σε 2.10 (Σχήμα 22) και την πιο καθαρή γεωμετρική οργάνωση (Σχήμα 21).
- **Regularization Trade-off:** Σε αντίθεση με το κλασικό weight decay (L1/L2), το Topological Loss δρα απευθείας στη γεωμετρία των αναπαραστάσεων. Η διατήρηση της accuracy στο 97.37% δείχνει ότι η τοπολογική απλοποίηση επιτυγχάνεται χωρίς απώλεια σε επιδόσεις, με ελάχιστη μείωση στο AUC (0.9917 $\rightarrow$ 0.9871).
- **Υπολογιστικό Κόστος:** Η χρήση αναλυτικής παραγώγου καθιστά το Topological Loss εφικτό για πρακτική χρήση, ωστόσο η πολυπλοκότητα $O(n^2 \log n)$ ανά batch και η ευαισθησία στην επιλογή του βάρους $\lambda_{\text{τοπο}}$ αποτελούν βασικούς περιορισμούς.

4 Συμπεράσματα

Η TDA αποκάλυψε ότι τα δεδομένα μας διαθέτουν πλούσια τοπολογική δομή που δεν είναι πάντα ορατή με παραδοσιακές μεθόδους στατιστικής ή μηχανικής μάθησης. Συγκεκριμένα:

1. Οι αριθμοί Betti και τα διαγράμματα εμμονής προσδιορίζουν με ακρίβεια τον αριθμό των οπών και των κοιλοτήτων στα σχήματα (κύκλος, τόρος, σφαίρα).
2. Η ανάλυση ευαισθησίας στον θόρυβο έδειξε ότι τα τοπολογικά χαρακτηριστικά είναι στιβαρά μέχρι ένα σημείο, αλλά ο έντονος θόρυβος μπορεί να αλλοιώσει τις αποστάσεις Bottleneck.
3. Ο αλγόριθμος Mapper αποδείχθηκε εξαιρετικό εργαλείο για την οπτικοποίηση σύνθετων δομών όπως το Figure-8 και το Horse-shoe, επιτρέποντας την κατανόηση της γεωμετρίας τους μέσω απλών γραφημάτων.
4. Η εξαγωγή τοπολογικών χαρακτηριστικών (Persistence Images) από το Takens Embedding του Breast Cancer dataset και η εισαγωγή τους σε ταξινομητή Random Forest απέδειξε ότι η καθαρά τοπολογική δομή των χαρακτηριστικών φέρει σημαντική διαγνωστική ικανότητα για τη διάγνωση του καρκίνου.
5. Η ανάλυση της χρονοσειράς S&P 500 μέσω Takens Embedding και επίμονης εντροπίας επέτρεψε την ποσοτικοποίηση της πολυπλοκότητας της αγοράς. Η επαλήθευση με GUDHI (Alpha Complex) επιβεβαίωσε την απουσία τρισδιάστατων κοιλοτήτων ($H_2 = 0$), ενώ το bootstrap resampling ($n = 100$) απέδειξε τη στατιστική σταθερότητα των τοπολογικών χαρακτηριστικών (ιδίως του H_0) έναντι δειγματοληπτικών διακυμάνσεων.
6. Η μέθοδος της Zigzag Persistent Homology επέτρεψε την επιτυχή καταγραφή της δυναμικής εξέλιξης των τοπολογικών δομών σε χρηματοοικονομικές χρονοσειρές, αναδεικνύοντας μεταβατικά τοπολογικά χαρακτηριστικά που συνδέονται με την αστάθεια της αγοράς.
7. Το Topological Loss ως regularization σε Neural Network (MLP) επέδειξε τη δυνατότητα αμεσότερου ελέγχου της γεωμετρίας του latent space. Η ελαχιστοποίηση της persistence ενδιάμεσων αναπαραστάσεων οδηγεί σε πιο συμπαγείς και διαχωρισμένες συστάδες ανά κλάση, ενισχύοντας τη διακριτική ικανότητα του μοντέλου χωρίς τη χρήση εξωτερικών βιβλιοθηκών.

5 Χρήση AI

Η χρήση Τεχνητής Νοημοσύνης (συγκεκριμένα Μεγάλων Γλωσσικών Μοντέλων - LLMs) έγινε στα εξής σημεία της εργασίας:

- **Ανάπτυξη Κώδικα:** Υποστήριξη στη συγγραφή και βελτιστοποίηση κώδικα Python σε όλα τα ερωτήματα της εργασίας (συμπεριλαμβανομένης της υλοποίησης του συμπλέγματος Vietoris–Rips εκ του μηδενός και του αλγορίθμου Custom Mapper).
- **Επίλυση Σφαλμάτων (Debugging):** Βοήθεια στην επίλυση σφαλμάτων συμβατότητας των βιβλιοθηκών GUDHI και Ripser, καθώς και στη διαχείριση της κωδικοποίησης (UTF-8) στο περιβάλλον των Windows.
- **Ερμηνεία Αποτελεσμάτων:** Συζήτηση και ανάλυση των διαγραμμάτων εμμονής και των γραφημάτων του Mapper για την καλύτερη κατανόηση των τοπολογικών δομών.

Σημείωση: Η τελική αξιολόγηση, ο έλεγχος της ορθότητας του κώδικα και η συγγραφή των τελικών συμπερασμάτων έγιναν από την ομάδα εργασίας.

6 Βιβλιογραφία

Αναφορές

- [1] Ανδρικόπουλος, Α. *Τοπολογική Ανάλυση Δεδομένων*. Πανεπιστήμιο Πατρών, Τμήμα Μηχανικών Η/Υ και Πληροφορικής.
- [2] GUDHI Editorial Board. *GUDHI User and Reference Manual*.
- [3] Bauer, U. (2021). *Ripser: efficient computation of Vietoris-Rips persistence barcodes*.
- [4] Carlsson, G., & de Silva, V. (2010). Zigzag Persistence. *Foundations of Computational Mathematics*, 10(4), 367-405.
- [5] Hofer, C., Kwitt, R., Niethammer, M., & Uhl, A. (2017). Deep Learning with Topological Signatures. *Advances in Neural Information Processing Systems (NeurIPS)*.
- [6] Chen, C., Ni, X., Bai, Q., & Wang, Y. (2019). A Topological Regularizer for Classifiers via Persistent Homology. *AISTATS*.