



ΠΑΝΕΠΙΣΤΗΜΙΟ
ΠΑΤΡΩΝ
UNIVERSITY OF PATRAS

Πανεπιστημιούπολη Ρίου · Πολυτεχνική Σχολή
Τμήμα Μηχανικών Η/Υ & Πληροφορικής (ΤΜΗΥΠ – CEID)

ΤΟΠΟΛΟΓΙΚΗ ΑΝΑΛΥΣΗ ΔΕΔΟΜΕΝΩΝ

(CEID_25EE606)

Εξαμηνιαία Εργασία — 2026

Ομάδα Εργασίας:

Βερύκιος Άγγελος (1100500)

Βογινατζής Αναστάσιος (1100506)

Κολύβρας Κωνσταντίνος (1103826)

11 Μαΐου 2026

Περιεχόμενα

1	<u>Θεωρητική Εισαγωγή</u>	2
1.1	Simplicial Complexes	2
1.2	Persistent Homology	2
1.3	Mapper	2
2	<u>Μεθοδολογία</u>	3
2.1	Βιβλιοθήκες	3
2.2	Αιτιολόγηση Επιλογών	3
3	<u>Αποτελέσματα & Ανάλυση</u>	4
3.1	Ερώτημα Α	4
3.1.1	A.1—Νέφος Σημείων & Vietoris–Rips (from scratch)	4
3.1.2	A.2—Σύγκριση VR/Cech/Alpha μέσω GUDHI	5
3.1.3	A.3—Filtration & Ανάλυση Κλίμακας	6
3.1.4	A.4—Οπτικοποίηση σε 3 Διαστάσεις (3D)	7
3.2	Ερώτημα Β	8
3.2.1	B.1: Persistent Homology από Νέφη Σημείων	8
3.2.2	B.2: Στιβαρότητα (Robustness) σε Gaussian Θόρυβο	8
3.2.3	B.3: Persistent Homology σε Γράφους	9
3.3	Ερώτημα Γ	11
3.3.1	Γ.1: Υλοποίηση Mapper εκ του Μηδενός	11
3.3.2	Γ.2: Εφαρμογή Mapper & Ανάλυση Ευαισθησίας	11
3.4	Ερώτημα Δ — Εφαρμογή σε Πραγματικά Δεδομένα	13
3.4.1	Δ.1 — Ανάλυση Πρώτου Dataset (Breast Cancer)	13
3.4.2	Δ.2 — Ανάλυση Δεύτερου Dataset (S&P 500)	14
3.4.3	Δ.3 — Βαθιά Σύγκριση & Συζήτηση: TDA vs Κλασικές Μέθοδοι	16
4	<u>Συμπεράσματα</u>	17
5	<u>Χρήση AI</u>	18
6	<u>Βιβλιογραφία</u>	19

1 Θεωρητική Εισαγωγή

Στην ενότητα αυτή παρουσιάζονται οι βασικές έννοιες της Τοπολογικής Ανάλυσης Δεδομένων (TDA).

1.1 **Simplicial Complexes**

Τα Simplicial Complexes αποτελούν τη διακριτή προσέγγιση των συνεχών τοπολογικών χώρων. Αποτελούνται από απλόπλοκα (simplices) διαφόρων διαστάσεων: 0-απλόπλοκα (σημεία), 1-απλόπλοκα (ακμές), 2-απλόπλοκα (τρίγωνα), 3-απλόπλοκα (τετράεδρα) κ.ο.κ. Η ένωση αυτών των στοιχείων με συγκεκριμένους κανόνες συνδυαστικότητας μας επιτρέπει να μοντελοποιήσουμε το σχήμα των δεδομένων και να υπολογίσουμε τοπολογικές ιδιότητες.

1.2 **Persistent Homology**

Η Persistent Homology είναι ένα εργαλείο που ανιχνεύει τοπολογικά χαρακτηριστικά (όπως συνεκτικές συνιστώσες, τρύπες, κοιλότητες) σε πολλαπλές κλίμακες. Καθώς αυξάνουμε την ακτίνα r γύρω από κάθε σημείο (διήθηση ή filtration), νέα απλόπλοκα δημιουργούνται. Η εμμονή (persistence) μετρά πόσο ‘ζει’ κάθε τοπολογικό χαρακτηριστικό. Χαρακτηριστικά που επιμένουν για μεγάλο εύρος τιμών του r θεωρούνται αληθή τοπολογικά σήματα, ενώ αυτά που πεθαίνουν γρήγορα θεωρούνται θόρυβος.

1.3 **Mapper**

Ο αλγόριθμος Mapper είναι μια τεχνική μείωσης διαστάσεων και οπτικοποίησης που διατηρεί την τοπολογική δομή των δεδομένων. Χρησιμοποιεί μια συνάρτηση φίλτρου (filter function) για να προβάλλει τα δεδομένα σε χαμηλότερη διάσταση, χωρίζει τον χώρο σε επικαλυπτόμενα διαστήματα, εφαρμόζει clustering στα σημεία κάθε διαστήματος και συνδέει τα clusters που μοιράζονται κοινά σημεία, δημιουργώντας ένα γράφημα που συνοψίζει τη δομή.

2 Μεθοδολογία

Για την υλοποίηση της εργασίας ακολουθήθηκε η εξής διαδικασία:

2.1 Βιβλιοθήκες

- GUDHI: Για την κατασκευή συμπλεγμάτων και τον υπολογισμό Persistent Homology στο Ερώτημα A.
- Ripser: Για τον γρήγορο υπολογισμό της Persistent Homology στο Ερώτημα B.
- Persim: Για τον υπολογισμό αποστάσεων Bottleneck και Wasserstein.
- NumPy & SciPy: Για τη διαχείριση δεδομένων και μαθηματικούς υπολογισμούς.
- Matplotlib & Plotly: Για την οπτικοποίηση των αποτελεσμάτων.

2.2 Αιτιολόγηση Επιλογών

Η επιλογή της GUDHI έγινε λόγω της πληρότητάς της σε διάφορα είδη συμπλεγμάτων (Alpha Complex, Cech Complex κ.λπ.), ενώ η Ripser επιλέχθηκε για την ταχύτητά της στον υπολογισμό του H_1 . Ο αλγόριθμος Mapper υλοποιήθηκε τόσο εκ του μηδενός (για βαθύτερη κατανόηση) όσο και μέσω της βιβλιοθήκης `kmapper` για επαλήθευση των αποτελεσμάτων.

3 Αποτελέσματα & Ανάλυση

3.1 Ερώτημα Α

3.1.1 A.1—Νέφος Σημείων & Vietoris–Rips (from scratch)


Εξήγηση Υλοποίησης: Για την υλοποίηση εκ του μηδενός, δημιουργήσαμε τα νέφη σημείων και υπολογίσαμε τον πίνακα αποστάσεων. Στη συνέχεια, για μια δεδομένη ακτίνα r , βρήκαμε όλες τις ακμές (αποστάσεις $\leq 2r$) και όλα τα τρίγωνα (κλίκες μεγέθους 3). Ο υπολογισμός των αριθμών Betti έγινε μέσω του πίνακα συνόρων (boundary matrix) και απαλοιφής Gauss.

Σημαντικό Κομμάτι Κώδικα:

```
1 # Finding edges and triangles (Simplices)
2 edges = []
3 for i in range(n):
4     for j in range(i+1, n):
5         if dist_matrix[i, j] <= 2 * r:
6             edges.append((i, j))
7
8 triangles = []
9 for i in range(n):
10     for j in range(i+1, n):
11         for k in range(j+1, n):
12             if dist_matrix[i, j] <= 2*r and dist_matrix[i, k] <= 2*r
13                 and dist_matrix[j, k] <= 2*r:
14                 triangles.append((i, j, k))
```

Σχολιασμός: Ο κώδικας αυτός ελέγχει όλους τους συνδυασμούς σημείων για να βρει αν σχηματίζουν ακμές ή τρίγωνα με βάση την ακτίνα r . Είναι η βάση για την κατασκευή του συμπλέγματος.

Αποτελέσματα & Ερμηνεία: Τα αποτελέσματα του υπολογισμού των αριθμών Betti για τον κύκλο με $\epsilon = 0.5$ έδωσαν $\beta_0 = 1$, $\beta_1 = 1$, $\beta_2 = 1$. Σημείωση: Η τιμή $\beta_2 = 1$ οφείλεται στην αποκοπή του συμπλέγματος στη διάσταση 2 (έλλειψη τετραέδρων).



Σχήμα 1: Τα 4 παραγόμενα νέφη σημείων. Παρατηρούμε τις διαφορετικές τοπολογικές δομές (κύκλος, τόρος, σφαίρα).


3.1.2 A.2—Σύγκριση VR/Cech/Alpha μέσω GUDHI

Αποτελέσματα & Ερμηνεία:

Πίνακας 1: Σύγκριση Συμπλεγμάτων για $r = 0.3$

Σύμπλεγμα	0-simplices	1-simplices	2-simplices	β_0	β_1	β_2
VR Complex	30	72	54	1	1	0
Cech Complex	30	56	26	1	1	0
Alpha Complex	30	37	7	1	1	0


Παρατηρούμε ότι το Alpha Complex παράγει πολύ λιγότερα απλόπλοκα (ακμές και τρίγωνα) σε σχέση με το VR, αλλά διατηρεί τους ίδιους αριθμούς Betti. Αυτό το καθιστά πολύ πιο αποδοτικό.




Σχήμα 2: Οπτικοποίηση του VR Complex. Τα σημεία είναι μπλε, οι ακμές κόκκινες και τα τρίγωνα πράσινα.

3.1.3 A.3—Filtration & Ανάλυση Κλίμακας

Αποτελέσματα & Ερμηνεία: Η τρύπα του κύκλου γεννιέται στο $r = 0.2$ (όταν οι ακμές κλείνουν τον κύκλο) και πεθαίνει στο $r = 0.9$ (όταν τα τρίγωνα γεμίζουν τον κύκλο).




Σχήμα 3: Διάγραμμα αριθμών Betti. Στο $r = 0.2$ εμφανίζεται ο $\beta_1 = 1$.



Σχήμα 4: Στιγμιότυπα της κατασκευής του συμπλέγματος για διάφορες τιμές του r .

3.1.4 A.4—Οπτικοποίηση σε 3 Διαστάσεις (3D)

Εξήγηση Υλοποίησης: Για τις δομές σε 3 διαστάσεις (όπως ο Τόρος και η Σφαίρα), η οπτικοποίηση του συμπλέγματος Vietoris–Rips απαιτεί την εμφάνιση των σημείων, των ακμών αλλά και των τριγώνων (2-simplices) στον τρισδιάστατο χώρο. Αυτό βοηθά στην κατανόηση του πώς τα απλόπλοκα ‘γεμίζουν’ τον χώρο και σχηματίζουν τις τοπολογικές τρύπες.



Σχήμα 5: Οπτικοποίηση του συμπλέγματος σε 3 διαστάσεις (3D) για τον Τόρο από δύο διαφορετικές οπτικές γωνίες.

3.2 Ερώτημα Β

3.2.1 B.1: Persistent Homology από Νέφη Σημείων


Εξήγηση Υλοποίησης: Χρησιμοποιήσαμε τη βιβλιοθήκη Ripser για τον υπολογισμό των διαγραμμάτων εμμονής. Η Ripser είναι εξαιρετικά γρήγορη και αποδοτική για αυτόν τον σκοπό.

Σημαντικό Κομμάτι Κώδικα:


```
1 from ripser import ripser
2 # Calculate Persistent Homology
3 result = ripser(data, maxdim=2)
4 diagrams = result['dgms']
```

Σχολιασμός: Η συνάρτηση *ripser* υπολογίζει αυτόματα τα διαγράμματα εμμονής μέχρι τη διάσταση που ορίζουμε (*maxdim*).

Αποτελέσματα & Ερμηνεία: Τα σημεία που βρίσκονται μακριά από τη διαγώνιο αντιπροσωπεύουν πραγματικά τοπολογικά χαρακτηριστικά που επιμένουν, ενώ τα σημεία κοντά στη διαγώνιο είναι θόρυβος.




Σχήμα 6: Persistence Diagrams για Τυχαία Σημεία και Θορυβώδη Κύκλο.



Σχήμα 7: Persistence Diagrams για Τόρο και Σφαίρα.

3.2.2 B.2: Στιβαρότητα (Robustness) σε Gaussian Θόρυβο


Αποτελέσματα & Ερμηνεία: Όπως φαίνεται στο διάγραμμα, η απόσταση Bottleneck και Wasserstein αυξάνεται καθώς αυξάνεται ο θόρυβος σ . Αυτό δείχνει την ευαισθησία των τοπολογικών χαρακτηριστικών στον θόρυβο.




Σχήμα 8: Επίδραση του θορύβου στις αποστάσεις Bottleneck και Wasserstein.

3.2.3 B.3: Persistent Homology σε Γράφους

Αποτελέσματα & Ερμηνεία: Υπολογίστηκαν δύο διαφορετικές διηθήσεις (filtrations). Τα αποτελέσματα δείχνουν πώς η επιλογή της διήθησης επηρεάζει τα τοπολογικά χαρακτηριστικά που ανιχνεύονται.



Σχήμα 9: Σύγκριση Persistence Diagrams για γράφους.



Σχήμα 10: Persistence Images για τους γράφους.

3.3 Ερώτημα Γ

3.3.1 Γ.1: Υλοποίηση Mapper εκ του Μηδενός

Εξήγηση Υλοποίησης: Υλοποιήσαμε τον αλγόριθμο Mapper από το μηδέν. Ο αλγόριθμος χωρίζει τον χώρο των τιμών του φίλτρου σε επικαλυπτόμενα διαστήματα, ομαδοποιεί τα σημεία που αντιστοιχούν σε κάθε διάστημα (χρησιμοποιώντας DBSCAN) και συνδέει τους κόμβους που μοιράζονται κοινά σημεία.


Σημαντικό Κομμάτι Κώδικα:

```
1 # Main logic of fit method in CustomMapper
2 for int_idx, interval_bounds in enumerate(intervals):
3     # Find points in interval
4     pts_idx = np.where(in_interval)[0]
5     # Cluster subset of points
6     labels = self.clustering_algo.fit_predict(X_subset)
7     # Add nodes and edges to graph
```

Σχολιασμός: Η λογική αυτή διατρέχει όλα τα διαστήματα και εφαρμόζει *clustering* για να βρει τους κόμβους του γραφήματος.


3.3.2 Γ.2: Εφαρμογή Mapper & Ανάλυση Ευαισθησίας

Αποτελέσματα & Ερμηνεία: Εφαρμόσαμε τον αλγόριθμο στα σύνολα δεδομένων Figure-8 και Horse-shoe με 3 διαφορετικές συναρτήσεις φίλτρου: PCA 1ης συνιστώσας, L2-norm και Density.




Σχήμα 11: Αποτελέσματα Custom Mapper για το Figure-8 με φίλτρα PCA, L2-norm και Density.

Σχολιασμός: Η τριάδα των γραφημάτων για το Figure-8 διαφέρει ανάλογα με το φίλτρο: 1. Το PCA διαχωρίζει τους δύο κύκλους (αριστερά-δεξιά) στον άξονα μέγιστης διασποράς. 2. Το L2-norm δείχνει την απόσταση από το κέντρο, δημιουργώντας μια δομή που 'ανοίγει' από το κέντρο προς τα άκρα. 3. Το Density αναδεικνύει το σημείο τομής των δύο κύκλους όπου η πυκνότητα των σημείων είναι μέγιστη.



Σχήμα 12: Αποτελέσματα Custom Mapper για το Horse-shoe με φίλτρα PCA, L2-norm και Density.

Σχολιασμός: Στο Horse-shoe: 1. Το PCA 'ξεδιπλώνει' την καμπύλη σε μια συνεχή γραμμική δομή. 2. Το L2-norm δίνει παρόμοιες τιμές σε όλα τα σημεία (αφού ισαπέχουν από το κέντρο), συμπυκνώνοντας το γράφημα. 3. Το Density δείχνει ότι η πυκνότητα είναι ομοιόμορφη κατά μήκος του πετάλου, διατηρώντας τη δομή ως μία συνεκτική συνιστώσα.



Σχήμα 13: Ανάλυση ευαισθησίας: Αριθμός συνεκτικών συνιστωσών συναρτήσει των παραμέτρων.

Σχολιασμός: Η ανάλυση ευαισθησίας δείχνει ότι ο αριθμός των συνεκτικών συνιστωσών εξαρτάται έντονα από τον αριθμό των διαστημάτων και το ποσοστό επικάλυψης. Μεγαλύτερη επικάλυψη οδηγεί σε πιο συνεκτικά γραφήματα.


3.4 Ερώτημα Δ — Εφαρμογή σε Πραγματικά Δεδομένα

Σε αυτή την ενότητα εφαρμόζουμε τις τεχνικές της Τοπολογικής Ανάλυσης Δεδομένων (TDA) σε δύο πραγματικά σύνολα δεδομένων: το dataset καρκίνου του μαστού (Breast Cancer Wisconsin) ως Κατηγορία I και τις χρονοσειρές των τιμών κλεισίματος του δείκτη S&P 500 των τελευταίων δύο ετών ως Κατηγορία II.

3.4.1 Δ.1 — Ανάλυση Πρώτου Dataset (Breast Cancer)

1. Προεπεξεργασία και Μείωση Διάστασης: Το σύνολο δεδομένων Breast Cancer περιλαμβάνει 569 δείγματα με 30 αριθμητικά χαρακτηριστικά που περιγράφουν πυρήνες κυττάρων από βιοψίες μαστού. Τα δεδομένα κατηγοριοποιούνται σε δύο κλάσεις: Malignant (κακοήθης, 212 δείγματα) και Benign (καλοήθης, 357 δείγματα). Πραγματοποιήθηκε τυποποίηση (Standardization) των δεδομένων με χρήση του `StandardScaler` ώστε όλα τα χαρακτηριστικά να έχουν μέση τιμή 0 και διασπορά 1. Στη συνέχεια, εφαρμόστηκε η μέθοδος PCA κρατώντας τις 5 κύριες συνιστώσες για τη διευκόλυνση του υπολογισμού της επίμονης ομολογίας.

2. Επίμονη Ομολογία (H_0, H_1): Υπολογίστηκε η επίμονη ομολογία για τις διαστάσεις 0 και 1 ξεχωριστά για την κλάση των κακοήθων και των καλοήθων δειγμάτων χρησιμοποιώντας τη βιβλιοθήκη `ripser`. Τα αποτελέσματα οπτικοποιούνται στα διαγράμματα εμμονής (Persistence Diagrams) και barcodes.



Σχήμα 14: Persistence Diagrams για την κλάση Malignant (αριστερά) και Benign (δεξιά).

Παρατηρούμε ότι οι δύο κλάσεις παρουσιάζουν διαφορές στην τοπολογική τους δομή. Η κλάση των καλοήθων δειγμάτων εμφανίζει πιο διάσπαρτα και μακρόβια χαρακτηριστικά H_1 (τρύπες) σε σχέση με την κλάση των κακοήθων, πράγμα που υποδηλώνει μια πιο σύνθετη και «ανοιχτή» γεωμετρική διάταξη στο χώρο των κύριων συνιστωσών.

3. Εφαρμογή Mapper: Κατασκευάστηκε το γράφημα Mapper χρησιμοποιώντας τη βιβλιοθήκη `kmapper`. Ως συνάρτηση φίλτρου χρησιμοποιήθηκε η προβολή PCA σε 2 διαστάσεις. Ο χώρος καλύφθηκε από 10 επικαλυπτόμενα διαστήματα με ποσοστό επικάλυψης 30% ανά διάσταση, και εφαρμόστηκε ο αλγόριθμος DBSCAN (με `eps=2.5` και `min_samples=3`) για το clustering των σημείων. Το διαδραστικό γράφημα Mapper αποθηκεύτηκε στο αρχείο `d1_mapper_graph.html`.

Το γράφημα αναδεικνύει τον διαχωρισμό των κλάσεων σε διαφορετικές περιοχές (branches) του γραφήματος, με μια περιοχή μετάβασης όπου συνυπάρχουν καλοήγη και κακοήγη δείγματα.

4. TDA ως Χαρακτηριστικά (Features) για Μηχανική Μάθηση: Για να χρησιμοποιήσουμε την τοπολογική πληροφορία σε ταξινόμηση, μετατρέψαμε το διάνυσμα χαρακτηριστικών κάθε ασθενούς (30 τιμές) σε χρονοσειρά / point cloud μέσω της μεθόδου Takens Embedding (με διάσταση 3 και καθυστέρηση 1). Στη συνέχεια, για κάθε ασθενή υπολογίστηκε η επίμονη ομολογία H_0 και τα διαγράμματα εμμονής μετατράπηκαν σε εικόνες εμμονής (Persistence Images) μέσω του PersistenceImager (με μέγεθος pixel 0.1). Οι εικόνες αυτές ισοπεδώθηκαν (flatten) σε μονοδιάστατα διανύσματα χαρακτηριστικών. Εκπαιδεύτηκε ένας ταξινομητής Random Forest με τα παρακάτω αποτελέσματα στο test set (30%):

- **Accuracy:** 0.6901
- **AUC Score:** 0.7152

Αν και η ακρίβεια αυτή είναι χαμηλότερη από τη χρήση των αρχικών δεδομένων άμεσα (καθώς το Takens embedding σε 30 features εισάγει θόρυβο), επιβεβαιώνει ότι η καθαρά τοπολογική δομή των χαρακτηριστικών φέρει σημαντική διακριτική ικανότητα για τη διάγνωση του καρκίνου.

3.4.2 Δ.2 — Ανάλυση Δεύτερου Dataset (S&P 500)

1. Δεδομένα και Giotto-TDA Pipeline: Φορτώθηκαν οι καθημερινές τιμές κλεισίματος του δείκτη S&P 500 ($\sim$ GSPC) για τα τελευταία 2 έτη μέσω της `yfinance`. Οι τιμές τυποποιήθηκαν και εφαρμόστηκε η μέθοδος Takens Embedding με διάσταση $d = 3$ και καθυστέρηση $\tau = 1$, μετατρέποντας τη μονοδιάστατη χρονοσειρά σε ένα τρισδιάστατο point cloud που αναπαριστά τη δυναμική της αγοράς. Κατασκευάστηκε ένα scikit-learn συμβατό pipeline μέσω της βιβλιοθήκης `giotto-tda` που περιλαμβάνει:


1. `TakensEmbedding` για την αναπαράσταση της χρονοσειράς σε 3D.
2. `VietorisRipsPersistence` για τον υπολογισμό των διαγραμμάτων εμμονής για τις διαστάσεις 0, 1 και 2.
3. `PersistenceEntropy` για τον υπολογισμό της επίμονης εντροπίας ως μέτρο πολυπλοκότητας της τοπολογίας της χρονοσειράς.

Η κανονικοποιημένη επίμονη εντροπία (Normalized Persistence Entropy) για το σύνολο των δεδομένων υπολογίστηκε σε:

- H_0 : 1.6775
- H_1 : 8.6782
- H_2 : -0.6358


2. Επαλήθευση H_2 Ομολογίας με GUDHI: Επειδή η διάσταση του point cloud είναι $d \geq 3$, υπολογίστηκε η ομολογία διάστασης 2 (H_2). Χρησιμοποιήθηκε το `AlphaComplex` της βιβλιοθήκης GUDHI για την επαλήθευση. Οι αριθμοί Betti που προέκυψαν ήταν $\beta = [1, 0, 0]$, γεγονός που δείχνει ότι το σύμπλεγμα είναι τοπολογικά ισοδύναμο με ένα μόνο σημείο (συνεχτικό σύμπλεγμα χωρίς 1-κύκλους ή 2-κοιλότητες στην τελική κλίμακα), επιβεβαιώνοντας ότι το Takens Embedding της χρηματοοικονομικής χρονοσειράς δεν σχηματίζει κλειστές σφαιρικές κοιλότητες ($H_2 = 0$).

3. Οπτικοποίηση και Μείωση Διάστασης: Η 3D τροχιά του Takens Embedding οπτικοποιήθηκε σε διαδραστικό γράφημα Plotly ([d2_sp500_3d_embedding.html](#)). Επιπλέον, το 3D point cloud οπτικοποιήθηκε και σε στατικό τρισδιάστατο γράφημα (embedding).



Σχήμα 15: Τρισδιάστατη τροχιά του Takens Embedding ($d = 3, \tau = 1$) για τη χρονοσειρά S&P 500.

Για τη σύγκριση, το 3D point cloud προβλήθηκε σε 2 διαστάσεις με 3 μεθόδους: PCA, t-SNE και UMAP.



Σχήμα 16: Σύγκριση μείωσης διάστασης του 3D Takens Embedding του S&P 500 με PCA, t-SNE και UMAP.

- Η PCA αποκαλύπτει τη γραμμική κατεύθυνση μέγιστης διασποράς της αγοράς.
- Το t-SNE δημιουργεί ξεχωριστές συστάδες, τονίζοντας τοπικές ομοιότητες αλλά καταστρέφοντας την παγκόσμια γεωμετρία της χρονοσειράς.

- Το UMAP διατηρεί καλύτερα τη συνέχεια της τροχιάς της χρονοσειράς, αναδεικνύοντας τη δομή «νήματος» (filament structure) των τιμών.

4. Bootstrap Resampling & Διαστήματα Εμπιστοσύνης (95%): Για να ελέγξουμε τη σταθερότητα της επίμονης εντροπίας, εφαρμόστηκε bootstrap resampling ($n = 100$) με τυχαία επιλογή του 80% των σημείων με επανατοποθέτηση. Τα 95% διαστήματα εμπιστοσύνης για την επίμονη εντροπία είναι:

- H_0 : Mean = 1.7014, 95% CI = [1.6596, 1.7349]
- H_1 : Mean = -12.2571, 95% CI = [-28.6147, -4.8745]
- H_2 : Mean = -0.2339, 95% CI = [-1.0000, -0.0000]

Τα στενά διαστήματα εμπιστοσύνης για το H_0 δείχνουν τη σταθερότητα της βασικής συνεκτικότητας των δεδομένων, ενώ οι αρνητικές τιμές και η διακύμανση στο H_1 και H_2 υποδηλώνουν την ευαισθησία και τον θόρυβο των ανώτερων τοπολογικών χαρακτηριστικών όταν υποδειγματίζεται το point cloud της χρονοσειράς.

3.4.3 Δ.3 — Βαθιά Σύγκριση & Συζήτηση: TDA vs Κλασικές Μέθοδοι

Η εφαρμογή των TDA μεθόδων στα δύο datasets ανέδειξε τα εξής πλεονεκτήματα έναντι των PCA, t-SNE και UMAP:

1. **Πολλαπλές Κλίμακες:** Οι κλασικές μέθοδοι μείωσης διάστασης απαιτούν την επιλογή μιας συγκεκριμένης κλίμακας (π.χ. perplexity στο t-SNE ή `n_neighbors` στο UMAP). Αντίθετα, η επίμονη ομολογία εξετάζει όλες τις κλίμακες ταυτόχρονα (μέσω του filtration r), διαχωρίζοντας με μαθηματική αυστηρότητα το σήμα από τον θόρυβο.
2. **Feature Extraction:** Η TDA επιτρέπει τη μετατροπή γεωμετρικών ιδιοτήτων σε ποσοτικά χαρακτηριστικά (όπως η Persistent Entropy και οι Persistence Images) που εισάγονται άμεσα σε μοντέλα μηχανικής μάθησης. Οι κλασικές μέθοδοι (όπως το t-SNE) δεν ορίζουν εύκολα μια αντίστροφη απεικόνιση ή μια γενικεύσιμη μεταμόρφωση για νέα δεδομένα (out-of-sample extension).
3. **Διατήρηση Σχήματος:** Ο Mapper και η επίμονη εντροπία αποτυπώνουν το «σχήμα» των δεδομένων (π.χ. βρόχους, διακλαδώσεις, κοιλότητες) το οποίο οι κλασικές προβολές (κυρίως η PCA) συμπιέζουν και καταστρέφουν. Στην ανάλυση χρονοσειρών (S&P 500), η TDA σε συνδυασμό με το Takens Embedding προσφέρει μια πλήρη εικόνα του χώρου φάσεων (phase space reconstruction), επιτρέποντας την ανίχνευση τοπολογικών αλλαγών που σχετίζονται με περιόδους αστάθειας στην αγορά.

4 Συμπεράσματα

Η TDA αποκάλυψε ότι τα δεδομένα μας διαθέτουν πλούσια τοπολογική δομή που δεν είναι πάντα ορατή με παραδοσιακές μεθόδους στατιστικής ή μηχανικής μάθησης. Συγκεκριμένα:

1. Οι αριθμοί Betti και τα διαγράμματα εμμονής προσδιορίζουν με ακρίβεια τον αριθμό των οπών και των κοιλοτήτων στα σχήματα (κύκλος, τόρος, σφαίρα).
2. Η ανάλυση ευαισθησίας στον θόρυβο έδειξε ότι τα τοπολογικά χαρακτηριστικά είναι στιβαρά μέχρι ένα σημείο, αλλά ο έντονος θόρυβος μπορεί να αλλοιώσει τις αποστάσεις Bottleneck.
3. Ο αλγόριθμος Mapper αποδείχθηκε εξαιρετικό εργαλείο για την οπτικοποίηση σύνθετων δομών όπως το Figure-8 και το Horse-shoe, επιτρέποντας την κατανόηση της γεωμετρίας τους μέσω απλών γραφημάτων.

5 Χρήση AI

Η χρήση Τεχνητής Νοημοσύνης (συγκεκριμένα Μεγάλων Γλωσσικών Μοντέλων - LLMs) έγινε στα εξής σημεία της εργασίας:

- **Ανάπτυξη Κώδικα:** Υποστήριξη στη συγγραφή και βελτιστοποίηση κώδικα Python σε όλα τα ερωτήματα της εργασίας (συμπεριλαμβανομένης της υλοποίησης του συμπλέγματος Vietoris–Rips εκ του μηδενός και του αλγορίθμου Custom Mapper).
- **Επίλυση Σφαλμάτων (Debugging):** Βοήθεια στην επίλυση σφαλμάτων συμβατότητας των βιβλιοθηκών GUDHI και Ripser, καθώς και στη διαχείριση της κωδικοποίησης (UTF-8) στο περιβάλλον των Windows.
- **Συγγραφή Αναφοράς σε L^AT_EX:** Υποστήριξη στη δομή του εγγράφου, στη διαχείριση των πακέτων γλωσσών (babel) για τη σωστή εναλλαγή ελληνικών και αγγλικών, και στη μορφοποίηση των πινάκων και των σχημάτων.
- **Ερμηνεία Αποτελεσμάτων:** Συζήτηση και ανάλυση των διαγραμμάτων εμμονής και των γραφημάτων του Mapper για την καλύτερη κατανόηση των τοπολογικών δομών.

Σημείωση: Η τελική αξιολόγηση, ο έλεγχος της ορθότητας του κώδικα και η συγγραφή των τελικών συμπερασμάτων έγιναν από την ομάδα εργασίας.

6 Βιβλιογραφία

Αναφορές

- [1] Ανδρικόπουλος, Α. *Τοπολογική Ανάλυση Δεδομένων*. Πανεπιστήμιο Πατρών, Τμήμα Μηχανικών Η/Υ και Πληροφορικής.
- [2] GUDHI Editorial Board. *GUDHI User and Reference Manual*.
- [3] Bauer, U. (2021). *Ripser: efficient computation of Vietoris-Rips persistence barcodes*.